

# Predição de Séries Temporais Meteorológicas com Frequências Mistas: Estudo de Caso com o Dataset INMET-Sorocaba (2006-2023)

Enzo Marcondes de Andrade Pereira Esteban, Felipe Zanardo Goldoni,  
Levi De Souza Correia, Leopoldo André Dutra Lusquino Filho, Matheus  
Lima Maturano Martins de Castro, Natan Da Silva Guedes, William  
Dantas Vichete

*<sup>a</sup>UNESP ICTS, Avenida 3 de março 511, Sorocaba, CEP, São Paulo, Brasil*

---

## Abstract

This work explores meteorological data from INMET for Sorocaba (2006-2023) to predict heavy rainfall using machine learning techniques. We focus on recurrent neural networks (RNNs), particularly LSTM and GRU, to handle temporal lags and mixed frequency time series. The study includes a detailed analysis of 2023 data and a broader attempt to process the entire dataset, which presents challenges. The proposed approach addresses defasages between variables like humidity and pressure, aiming to improve rainfall prediction accuracy. The results highlight both the potential and limitations of the model for weather forecasting.

*Keywords:* Deep Learning, LSTM, GRU, heavy rainfall

---

## 1. Introduction

Nos últimos anos, a previsão de eventos meteorológicos extremos tem se tornado cada vez mais crítica devido ao aumento da frequência de desastres naturais e suas implicações econômicas e sociais. Eventos climáticos severos, como chuvas intensas, podem causar inundações, deslizamentos de terra e outros fenômenos que impactam diretamente a vida urbana, o que ressalta a importância de sistemas de previsão confiáveis e precisos. Neste contexto, a utilização de técnicas avançadas de aprendizado de máquina aplicadas a séries temporais meteorológicas oferece um potencial significativo para melhorar a precisão das previsões.

Este trabalho se propõe a explorar o dataset meteorológico do Instituto Nacional de Meteorologia (INMET), específico para a cidade de Sorocaba, que abrange o período de 2006 a 2023, visando a predição de chuvas intensas e a correlação com variáveis meteorológicas, como umidade e pressão. O foco está no desenvolvimento de uma abordagem baseada em redes neurais recorrentes (RNNs), mais especificamente os modelos Long Short-Term Memory (LSTM) e Gated Recurrent Unit (GRU), que são adequados para lidar com as complexidades inerentes às séries temporais, como defasagens temporais e frequências mistas.

O principal desafio identificado neste trabalho foi o tratamento de séries temporais com diferentes frequências, o que requer a aplicação de técnicas para ajuste de defasagens e sincronização de variáveis explicativas com os eventos de chuva. A umidade, por exemplo, tende a aumentar antes de uma chuva, e a pressão atmosférica costuma cair — esses eventos estão correlacionados de forma defasada no tempo. Portanto, a abordagem proposta utiliza um pipeline que manipula lags e utiliza redes neurais para capturar esses padrões.

A análise deste trabalho é composta por duas partes: uma focada nos dados de 2023, que foram utilizados para estabelecer uma linha de base, e uma análise agregada do período 2006-2023, que ainda enfrenta desafios relacionados à concatenação e limpeza dos dados. O objetivo final é desenvolver uma solução robusta para a predição de chuvas intensas, abordando as dificuldades específicas associadas a séries temporais meteorológicas complexas e suas variáveis interrelacionadas.

## 2. Related Works

Nesta seção, serão revisados os trabalhos relacionados ao problema, focando majoritariamente em soluções recentes dos últimos cinco anos. Primeiramente, abordou-se soluções sem o uso de machine learning, utilizando modelos estatísticos e econométricos como o SARIMA e regressão linear. Em seguida, foram discutidas soluções baseadas em aprendizado de máquina, com destaque para os trabalhos de Nwokike et al. (2020) [1] e Parviz (2020) [2], que fazem uma comparação da eficiência de modelos de machine learning em relação a modelos estatísticos.

A previsão precisa de chuvas é crucial para diversas atividades, como agricultura, gestão de recursos hídricos e planejamento urbano. A pesquisa de Fatima et al. (2022) [3] demonstrou a eficácia do modelo SARIMA (Seasonal

AutoRegressive Integrated Moving Average) na previsão de chuvas em áreas costeiras. O modelo SARIMA é uma ferramenta estatística amplamente utilizada para modelar e prever séries temporais que apresentam componentes de tendência, sazonalidade e autocorrelação. O artigo de Fatima et al. (2022) [3] destaca a capacidade do SARIMA em capturar os padrões complexos das chuvas, especialmente em regiões com características climáticas sazonais. Comparativamente, o estudo de Nwokike et al. (2020) [1] comparou a eficiência de redes neurais estatísticas (SANN) e do modelo SARIMA para a previsão de chuvas utilizando quatro medidas de desempenho de previsão, demonstrando que ambos os modelos, SARIMA e SANN, podem ser eficazes na previsão da frequência de precipitação em Umuahia, Nigéria.

Além da metodologia SARIMA, a regressão linear é outra técnica estatística utilizada para predição de chuvas. Trata-se de um método estatístico tradicional que modela a relação linear entre variáveis. Na previsão de chuvas, a RLC pode ser utilizada para relacionar a precipitação com variáveis como temperatura, umidade e pressão atmosférica como é mostrado em Udomboso (2011) [4]. O trabalho feito por Udomboso (2011) [4] investigou e comparou a eficácia entre os modelos de Rede Neural Estatística (SNN) e a Regressão Linear Clássica (RLC) e demonstrou que apesar da RLC ainda ser utilizada na previsão de chuvas, modelos mais complexos, como as redes neurais estatísticas, podem oferecer um desempenho superior, especialmente ao considerar um número maior de variáveis.

À vista dos artigos citados anteriormente, nota-se que podem ser utilizadas metodologias sem o uso de machine learning para capturar padrões sazonais e tendências em séries temporais de precipitação, como o modelo SARIMA e a regressão linear. Entretanto, essas ferramentas podem apresentar limitações em lidar com complexidades não lineares e grandes volumes de dados. Dessa forma, a pesquisa de Parviz (2020) [2] demonstra que algumas técnicas de aprendizado de máquina têm demonstrado superioridade em relação a modelos estatísticos e são capazes de aprender padrões complexos e não lineares nos dados. Segundo o trabalho de Parviz (2020) [2], redes neurais artificiais (ANN) e máquinas de vetores de suporte (SVM), têm demonstrado superioridade em relação a modelos estatísticos, porém foi constatado que modelos híbridos que combinam SARIMA e técnicas de aprendizado de máquina podem oferecer um desempenho ainda melhor, aproveitando as vantagens de ambos os métodos.

Portanto, o presente estudo busca explorar a previsão de séries temporais meteorológicas utilizando o dataset INMET-Sorocaba. Modelos estatísticos

tradicionais seguem sendo uma boa alternativa quando as séries temporais possuem uma única frequência e em dados de alta qualidade. Porém, tendo em vista que este trabalho explora séries temporais meteorológicas com frequências mista e com dados ausentes e inconsistências, a utilização de modelos deep learning demonstrou ser a melhor alternativa para resolução da problemática. A escolha das redes recorrentes LSTM e GRU se justifica pela capacidade desses modelos em capturar dependências temporais de longo prazo e lidar com a não linearidade dos dados. Em linha com os trabalhos de Wijaya et al. (2023) [5], que demonstraram a eficácia do LSTM e GRU na previsão de chuvas em Palembang, este estudo busca avaliar o desempenho dessas arquiteturas considerando as particularidades do dataset INMET-Sorocaba e comparando-as com o modelo estatístico SARIMA, com o objetivo de identificar qual arquitetura apresenta o melhor desempenho para a previsão de chuvas em Sorocaba, considerando tanto a precisão quanto a eficiência computacional.

### 3. Proposed Approach

Neste trabalho, propomos uma abordagem híbrida para a predição de séries temporais meteorológicas, especificamente para eventos de chuva, umidade e pressão em Sorocaba, utilizando o dataset INMET-Sorocaba no período de 2006-2023. O foco da abordagem está em lidar com séries temporais de frequências mistas, correlações temporais defasadas entre variáveis, e a identificação de padrões subjacentes que possam antecipar eventos de chuva intensa. Nossa abordagem é dividida em três etapas principais: análise exploratória e pré-processamento, modelo preditivo baseado em LSTM e GRU, e avaliação e ajuste dos resultados.

#### 3.1. *Análise e Pré-processamento dos Dados*

O primeiro passo foi realizar duas análises independentes sobre o dataset. A primeira análise focou-se exclusivamente nos dados de 2023, enquanto a segunda visava a concatenação dos dados meteorológicos de 2006 a 2023. Durante o processo de concatenação de dados de múltiplos anos, enfrentamos diversas dificuldades relacionadas a inconsistências nos dados (como diferentes formatos e falta de padronização). Esse desafio impediu um progresso satisfatório na análise geral e mostrou a necessidade de uma limpeza de dados mais sofisticada, além de métodos mais robustos para lidar com séries temporais em frequências mistas.

A análise focada em 2023 serviu como uma base fundamental para entender as dinâmicas das variáveis e sua interdependência, especialmente em eventos climáticos severos como podemos observar na figura 1. Identificamos que a umidade geralmente aumenta e a pressão cai antes de eventos de chuva, mas essas correlações são defasadas no tempo. Portanto, nossa abordagem requer a manipulação cuidadosa de lags temporais para capturar essas relações.




Figure 1: Análise de um evento diário 20/01/2023 á 21/01/2023

### 3.2. Discussão Matemática da Arquitetura

A abordagem proposta neste trabalho baseia-se na aplicação de redes neurais recorrentes (RNNs), com destaque para duas variações: Long Short-Term Memory (LSTM) e Gated Recurrent Unit (GRU). Esses modelos são amplamente reconhecidos por sua capacidade de capturar dependências temporais de longo prazo, uma característica essencial em séries temporais meteorológicas, como as utilizadas neste estudo. A escolha desses modelos deve-se à necessidade de lidar com defasagens temporais e eventos meteorológicos que ocorrem em frequências diferentes, como umidade e pressão atmosférica, que têm correlações temporais com a precipitação.

A arquitetura LSTM se destaca por sua estrutura de células de memória, projetadas para armazenar e atualizar informações ao longo do tempo, o que permite que o modelo “lembre” padrões relevantes em longas sequências temporais. A principal característica matemática do LSTM é a combinação de três gates (portas): o input gate  $i_t$ , o forget gate  $f_t$  e o output gate  $o_t$ , que controlam o fluxo de informações pela célula de memória. Esses gates são definidos pelas seguintes equações:

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (1)$$

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (2)$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (3)$$

Onde  $h_{t-1}$  é o estado oculto da etapa anterior,  $x_t$  é o input atual,  $W$  são os pesos da rede,  $b$  são os biases e  $\sigma$  é a função sigmoide. O estado da célula  $C_t$  é atualizado conforme a equação:

$$C_t = f_t \cdot C_{t-1} + i_t \cdot \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (4)$$

Por outro lado, o GRU simplifica essa estrutura ao combinar o forget e o input gate em um único gate, resultando em uma arquitetura mais simples e computacionalmente eficiente. As equações que governam o GRU são:

$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t] + b_z) \quad (5)$$

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t] + b_r) \quad (6)$$

$$h_t = (1 - z_t) \cdot h_{t-1} + z_t \cdot \tanh(W_h \cdot [r_t \cdot h_{t-1}, x_t] + b_h) \quad (7)$$

Onde  $z_t$  é o gate de atualização e  $r_t$  é o gate de reset, que controla a atualização do estado oculto  $h_t$ . Esta simplificação faz do GRU uma escolha atraente para conjuntos de dados menores ou para modelos onde a eficiência computacional é uma prioridade.

As arquiteturas LSTM e GRU apresentam vantagens significativas em relação a modelos autoregressivos tradicionais, como ARIMA, que são eficazes para séries temporais lineares e estacionárias, mas enfrentam limitações ao lidar com padrões não-lineares e complexos típicos de dados meteorológicos. Ambas as RNNs são projetadas para capturar dependências temporais complexas: o LSTM é particularmente eficaz em sequências longas com correlações temporais distantes, enquanto o GRU, sendo mais simples e computacionalmente eficiente, é mais adequado para conjuntos de dados menores ou quando há necessidade de otimização.

Assim, a escolha entre LSTM e GRU deve levar em consideração as características do conjunto de dados e os requisitos computacionais do projeto. No contexto deste trabalho, onde os dados meteorológicos de Sorocaba apresentam padrões temporais complexos e defasagens, ambas as arquiteturas foram avaliadas em um benchmark cuidadoso para determinar a melhor abordagem para as previsões de chuvas intensas. Conforme ilustrado na Figura 2 abaixo, o modelo GRU apresentou um desempenho superior em relação aos eventos de alta precipitação; no entanto, ainda não conseguimos alcançar resultados satisfatórios.




Figure 2: Comparação de predição de temperatura no tempo

### 3.3. Comparação com Abordagens Anteriores

Em comparação com as abordagens discutidas na Seção 02, nosso método se destaca pela sua capacidade de lidar efetivamente com defasagens temporais, uma limitação significativa nos modelos baseados em regressão linear e SARIMA. Essas abordagens, comumente utilizadas em previsões meteorológicas, não abordam diretamente as interações dinâmicas e a temporalidade complexa dos dados. Por exemplo, estudos anteriores, como o de Fatima et al. (2022) [3], demonstraram a eficácia do modelo SARIMA para previsões de chuvas em áreas costeiras, mas sua aplicação muitas vezes se limita a padrões lineares e não considera a defasagem nas variáveis meteorológicas.

Além disso, a pesquisa de Nwokike et al. (2020) [1] comparou métodos tradicionais, como SARIMA, com redes neurais artificiais para prever a frequência de chuvas mensais. Embora os resultados tenham mostrado promissora capacidade preditiva, a modelagem de eventos não-lineares e as interações temporais complexas permanecem um desafio. Nesse contexto, o uso de técnicas de deep learning, como LSTM e GRU, revelou-se mais eficaz, visto que testamos o uso com SARIMA, o qual será melhor discutido na seção 4. Essas arquiteturas são projetadas para capturar a inter-relação entre variáveis meteorológicas em séries temporais longas, permitindo um aprendizado mais profundo das dinâmicas temporais, como as defasagens



observadas entre um aumento da umidade e uma queda na pressão antes da ocorrência de chuvas.

Portanto, a implementação de LSTM e GRU em nosso estudo não apenas propõe uma alternativa mais robusta, mas também se alinha às necessidades específicas de previsão de chuvas intensas, superando as limitações das abordagens convencionais. Essa abordagem nos permite melhorar a precisão das previsões, possibilitando uma melhor preparação para eventos meteorológicos extremos.

## 4. Experiments

Nesta seção, detalhamos os experimentos conduzidos para avaliar a eficácia dos modelos de deep learning, com foco em redes recorrentes (LSTM e GRU), na previsão de chuvas intensas. Descrevemos a metodologia de validação, o setup de hardware, a escolha dos hiperparâmetros e as métricas utilizadas, além da interpretação dos resultados obtidos, tanto do ponto de vista computacional quanto no domínio meteorológico.

### 4.1. Metodologia Experimental

A base de dados utilizada foi o conjunto meteorológico INMET-Sorocaba (2006-2023), que abrange informações horárias de variáveis críticas para previsão de chuvas intensas. A seleção cuidadosa das colunas incluiu:

- Precipitação Total, Horário (mm)
- Pressão Atmosférica ao Nível da Estação, Horário (mB)
- Temperatura Máxima na Hora Anterior (°C)
- Temperatura Mínima na Hora Anterior (°C)
- Umidade Relativa do Ar, Horário (%)

Essas variáveis foram escolhidas devido à sua relevância comprovada na modelagem de fenômenos climáticos extremos, como chuvas fortes, onde há correlações temporais complexas e defasadas entre as variáveis.

Para garantir a robustez dos modelos, foi realizada a normalização dos dados, padronizando-os em um intervalo de 0 a 1, o que permite uma convergência mais estável durante o treinamento de redes neurais. Criamos

janelas temporais de 24 horas, onde a sequência de entrada consistia nos dados das 24 horas anteriores e a saída visava prever a próxima hora.

A divisão do conjunto de dados foi feita em 80% para treinamento e 20% para teste, garantindo uma validação sólida dos modelos ao evitar overfitting e ajustar hiperparâmetros com base em dados não vistos durante o treinamento.

#### *4.2. Setup de Hardware*

Os experimentos foram realizados no Google Colab, uma plataforma amplamente utilizada para desenvolvimento e experimentação de modelos de machine learning, especialmente redes neurais profundas. O Colab oferece acesso a GPUs de alto desempenho, o que foi essencial para acelerar o treinamento dos modelos e otimizar o tempo de experimentação.

A configuração de hardware utilizada durante os experimentos foi a seguinte:

- **Plataforma:** Google Colab
- **Processador:** Intel Xeon (single-core, 2.30GHz)
- **GPU:** NVIDIA Tesla T4 (quando ativada) com 16 GB de memória dedicada
- **Memória RAM:** 12.6 GB disponíveis para o notebook
- **Armazenamento:** 68.4 GB disponíveis em disco

A ativação da GPU NVIDIA Tesla T4 é utilizada para reduzir o tempo de treinamento dos modelos LSTM e GRU, que são intensivos em processamento devido à sua complexidade e ao grande volume de dados temporais.

#### *4.3. Configuração dos Modelos e Hiperparâmetros*

Optamos pela implementação de dois modelos de redes neurais recorrentes: Long Short-Term Memory (LSTM) e Gated Recurrent Unit (GRU). A escolha por essas arquiteturas foi baseada na capacidade superior de ambas para capturar dependências temporais de longo prazo, um requisito indispensável em séries temporais meteorológicas que envolvem variáveis inter-relacionadas com defasagens temporais.

#### 4.3.1. *Modelo LSTM*

O modelo LSTM foi construído com a seguinte arquitetura:

- 100 unidades na primeira camada LSTM
- Dropout de 30% após a primeira camada LSTM, visando reduzir o overfitting
- Batch Normalization para estabilizar a distribuição dos gradientes e acelerar a convergência
- Segunda camada LSTM com 50 unidades
- Camada densa com 20 unidades e ativação ReLU, aplicada para extrair representações não lineares das saídas
- Camada de saída com a mesma dimensionalidade da variável alvo

O modelo foi treinado por 50 épocas, com batch size de 32, utilizando o otimizador Adam e a função de perda mean squared error (MSE), ajustada para dados contínuos.

#### 4.3.2. *Modelo GRU*

O modelo GRU foi configurado de forma similar ao LSTM, com a adição das mesmas camadas de Dropout e Batch Normalization, e apresentou uma arquitetura mais simples:

- 100 unidades GRU na primeira camada
- Segunda camada com 50 unidades GRU
- Camada densa com 20 unidades, seguida por uma camada de saída.

Embora o GRU seja uma arquitetura simplificada, ele frequentemente oferece resultados similares ao LSTM, com a vantagem de uma maior eficiência computacional.

#### 4.4. Métricas de Avaliação

Para avaliar a eficácia dos modelos LSTM e GRU na previsão de chuvas intensas, utilizamos um conjunto de métricas amplamente reconhecidas na literatura de machine learning. Essas métricas fornecem insights sobre a precisão das previsões e a capacidade dos modelos de capturar a variabilidade dos dados meteorológicos.

O Modelo LSTM obteve um Erro Médio Quadrático (MSE) de 0,0075, refletindo a média das diferenças quadráticas entre os valores previstos e os reais. O Erro Quadrático Médio (RMSE) foi calculado como 0,0866, indicando que, em média, as previsões do modelo diferem da realidade em aproximadamente 0,0866 mm de precipitação. Este valor é especialmente relevante em meteorologia, onde pequenas variações podem ter impactos significativos. Além disso, o Erro Médio Absoluto (MAE) do modelo LSTM foi de 0,0300, oferecendo uma visão direta do erro médio das previsões, sem considerar a direção dos desvios. O Coeficiente de Determinação ( $R^2$ ) foi de 0,0278, sugerindo que o modelo é capaz de explicar cerca de 2,78% da variabilidade dos dados, o que indica que há espaço para melhorias na captura de padrões complexos.

Por outro lado, o Modelo GRU apresentou resultados muito semelhantes, com um MSE de 0,0075 e um RMSE de 0,0866, demonstrando uma precisão comparável ao LSTM. O MAE do GRU foi de 0,0343, implicando que as previsões deste modelo tendem a apresentar um erro médio ligeiramente maior em comparação ao LSTM. O  $R^2$  para o GRU foi de 0,0267, indicando que este modelo é capaz de explicar aproximadamente 2,67% da variabilidade dos dados.

Em contraste, o modelo SARIMA apresentou um MSE de 0,0109, que é significativamente maior do que os dos modelos LSTM e GRU, indicando um desempenho inferior na previsão de chuvas. O RMSE foi de 0,1044, sugerindo que as previsões do SARIMA divergem em média cerca de 0,1044 mm da realidade, o que pode ter um impacto considerável em cenários meteorológicos, como podemos observar abaixo na figura 3, onde há uma grande inconsistência utilizando SARIMA.




Figure 3: Gráfico comparativo de Modelos

O MAE foi de 0,0490, o que significa que o erro médio absoluto das previsões do SARIMA também foi mais alto. Finalmente, o  $R^2$  negativo de -0,4136 revela que o modelo não conseguiu explicar a variabilidade dos dados, o que é um forte indicativo de que o SARIMA não é adequado para este conjunto específico de dados meteorológicos.

Os resultados das métricas estão apresentados na tabela abaixo:

Modelo	MSE	RMSE	MAE	$R^2$
LSTM	0.0075	0.0866	0.0300	0.0278
GRU	0.0075	0.0866	0.0343	0.0267
SARIMA	0.0109	0.1044	0.0490	-0.4136

Table 1: Resultados das métricas de avaliação para os modelos LSTM, GRU e SARIMA.

Essas métricas foram fundamentais para avaliar e comparar o desempenho dos modelos de deep learning, oferecendo uma visão clara sobre sua capacidade de previsão em um contexto meteorológico complexo. As semelhanças nas métricas entre LSTM e GRU evidenciam a eficácia de ambas as abordagens, enquanto as diferenças sutis, especialmente em comparação com o SARIMA, indicam potenciais caminhos para ajustes e melhorias futuras.

#### *4.5. Interpretação dos Resultados no Contexto Meteorológico*

Os modelos de deep learning demonstraram uma eficácia notável na captura das correlações temporais entre variáveis meteorológicas cruciais, como umidade, pressão atmosférica e precipitação. Essa habilidade de modelar interações complexas é fundamental para previsões precisas de chuvas intensas, que frequentemente apresentam padrões não lineares e defasagens temporais. A precisão elevada alcançada pelos modelos LSTM e GRU representa um avanço significativo em relação aos métodos tradicionais, como o SARIMA, que lutam para lidar com a complexidade inerente aos dados meteorológicos.

A capacidade de prever chuvas intensas com maior exatidão não só melhora a compreensão dos fenômenos climáticos, mas também permite uma gestão de desastres naturais mais eficaz. Com alertas antecipados mais precisos, as autoridades podem implementar medidas proativas em regiões vulneráveis, como Sorocaba, onde a incidência de enchentes pode ter consequências devastadoras para a infraestrutura urbana e a segurança pública.

Além disso, a aplicação de técnicas avançadas de aprendizado de máquina em meteorologia pode contribuir para um sistema de previsão mais robusto, integrando dados de diferentes fontes e escalas temporais. Isso permite um melhor planejamento e resposta a eventos climáticos extremos, resultando em uma mitigação mais eficaz dos riscos associados. Assim, os resultados deste estudo não apenas validam a eficácia dos modelos de deep learning, mas também abrem caminho para inovações na previsão e gestão de desastres naturais.

#### *4.6. Perspectiva Computacional*

O modelo GRU destacou-se pela sua eficiência em convergência e menor demanda por recursos computacionais, tornando-o uma opção altamente viável para implementações em larga escala e em tempo real. Sua arquitetura simplificada permite que o GRU processe dados de forma mais rápida, o que é particularmente valioso em cenários em que a latência e a rapidez de resposta são críticas, como em sistemas de alerta de enchentes e monitoramento meteorológico contínuo.

Por outro lado, o modelo LSTM, embora tenha demonstrado uma precisão superior em previsões, requer um poder computacional mais elevado. Isso se deve à sua arquitetura mais complexa, que inclui múltiplas portas e uma estrutura de memória que permite a captura de dependências de longo prazo em sequências temporais. Assim, o LSTM é mais adequado para cenários

onde a máxima precisão é essencial e onde há recursos computacionais suficientes para suportar seu treinamento e inferência.

Essa distinção entre os dois modelos ilustra a necessidade de equilibrar precisão e eficiência ao escolher a arquitetura mais apropriada para aplicações específicas. Em suma, enquanto o GRU oferece uma solução prática para previsões rápidas e em tempo real, o LSTM permanece como uma escolha poderosa quando a exatidão das previsões é a principal prioridade.

## 5. Conclusion

Este estudo investigou a aplicação de modelos de deep learning especificamente LSTM e GRU—na previsão de chuvas intensas, utilizando dados meteorológicos da cidade de Sorocaba. Ambos os modelos demonstraram uma capacidade notável de capturar dependências temporais complexas entre variáveis meteorológicas, como umidade, pressão atmosférica e precipitação, superando métodos tradicionais, como o SARIMA. O LSTM mostrou-se levemente mais preciso, mas ao custo de uma maior demanda computacional, enquanto o GRU ofereceu um equilíbrio superior entre precisão e eficiência, tornando-se uma escolha viável para aplicações em tempo real.

As métricas de avaliação revelaram que ambos os modelos de redes neurais recorrentes são capazes de lidar com os desafios impostos pelas séries temporais meteorológicas, oferecendo previsões significativamente mais precisas do que o SARIMA. Isso ressalta a importância de utilizar técnicas avançadas de aprendizado de máquina para previsões climáticas, especialmente em um contexto de crescente necessidade de alertas antecipados para desastres naturais, como enchentes.

Do ponto de vista computacional, o GRU destacou-se por sua eficiência em convergência e menor uso de recursos, ideal para implementações em grande escala e cenários onde a rapidez é crucial. O LSTM, embora mais intensivo em termos de recursos, apresentou uma precisão ligeiramente superior, sendo mais adequado para aplicações em que a máxima exatidão é fundamental.

Em termos práticos, a aplicação desses modelos em sistemas de alerta precoce pode melhorar significativamente a gestão de desastres naturais em regiões vulneráveis, como Sorocaba, proporcionando mais tempo para que medidas preventivas sejam tomadas.

Futuras pesquisas poderiam explorar a integração de outras variáveis meteorológicas e técnicas de ensemble para melhorar ainda mais a precisão das previsões, além de avaliar o impacto de redes neurais mais profundas e arquiteturas híbridas que combinem os pontos fortes de ambos os modelos.



## References

- [1] C. C. Nwokike, B. C. Offorha, M. Obubu, C. B. Ugoala, H. I. Ukomah, Comparing sann and sarima for forecasting frequency of monthly rainfall in umuahia, *Scientific African* 10 (2020) e00621. URL: <https://www.sciencedirect.com/science/article/pii/S2468227620303586>. doi:<https://doi.org/10.1016/j.sciaf.2020.e00621>.
- [2] L. Parviz, K. Rasouli, A. Torabi Haghighi, Comparative evaluation of hybrid sarima and machine learning techniques based on time varying and decomposition of precipitation time series, *Journal of Agricultural Science and Technology* 22 (2020) 563–578. URL: <http://jast.modares.ac.ir/article-23-26018-en.html>. doi:10.1109/PICMET.2016.7806831.
- [3] N. Fatima, A. Alamgir, M. Khan, Rainfall forecast using sarima model along the coastal areas of sindh province, *International Journal of Economic and Environmental Geology* 13 (2022) 35–41. doi:10.46660/ijeeg.v13i4.51.
- [4] C. G. Udomboso, G. N. Amahia, Comparative analysis of rainfall prediction using statistical neural network and classical linear regression model, *Journal of Modern Mathematics and Statistics* 5 (2011) 66–70. URL: <http://repository.ui.edu.ng/handle/123456789/5329>.
- [5] S. Wijaya, T. B. Kurniawan, E. S. Negara, Y. N. Kunang, Rainfall prediction in Palembang city using the gru and lstm methods, *Journal of Data Science* 2023 (2023).